

Выбор согласованных моделей для построения нейроинтерфейса

Кулаков Ярослав

February 2021

1 Аннотация

В работе исследуется задача построения нейро-компьютерного интерфейса (BCI). Рассматривается задача предсказания трехмерной траектории движения кисти по сигналам с коры головного мозга (ECoG). Сложность задачи состоит в том, что приходится работать с высокоразмерными и сильно скоррелированными данными. Предлагается применить методы снижения размерности исходного пространства. Для решения задачи используются линейные и нелинейные модели. Проводится анализ прогноза и латентного пространства, получаемых парой гетерогенных моделей. Экспериментальные результаты подтверждают, что предлагаемый метод улучшает качество предсказаний модели.

2 Введение

Нейрокомпьютерные интерфейсы предоставляют возможность интерпретации мозга, возможность получать разную информацию об активности мозга, использовать и обрабатывать ее моделями машинного обучения с целью

предсказания действий или декодирования мыслей человека. Из-за высокой сложности мозга и большого количества информации, содержащейся в нем в каждый момент времени, BCI сталкивается с проблемами, такими как высокая размерность получаемых данных электроэнцефалограммы и электрокортикограммы и скоррелированности их временных рядов. Для получения нескоррелированных, но информативных признаков, решается задача снижения размерности исходного пространства.[3] В работе предлагается исследовать разные модели машинного обучения: линейные и нелинейные нейросети. Оценивается качество, устойчивость и сложность рассматриваемых моделей.

В статье (Катруца, Стрижов, 2017)[2] даны обширные сравнения алгоритмов снижения размерности: QPFS с LARS, Lasso, Stepwise, Ridge и отбор признаков с генетическим алгоритмом. Quadratic Programming Feature Selection (QPFS) [2] превосходит конкурентов и этот метод можно адаптировать для нашей задачи. Так же проводится сравнение с методами PLS, PCA, других нелинейных моделей. При решении задачи выбора признаков, одновременно оптимизируются две задачи: минимизируется корреляция между признаками и максимизируется информативность признаков по отношению к таргету. Задача осложняется тем, что признаки и таргеты имеют разную природу.

В данной работе получен устойчивый пайплайн модулирования сигнала в конечности от карты активности мозга, состоящий из этапов:

- Построение латентного пространства меньшей размерности, с минимальной корреляцией признаков и максимальной информативностью.
- Построение прогностической модели в полученном пространстве.
- Восстановление обратной зависимости для предсказания активности мозга.

3 Постановка задачи

Рассматривается датасет (X, Y) . $X \in \mathbb{R}^{T, K}$, где T — количество временных отметок, а K — количество электродов, используемых для снятия сигнала. $Y \in \mathbb{R}^{C, T}$, где C — номер координаты в трехмерном пространстве. Данные содержат записи о траектории движения руки в 3х-мерном пространстве и ECoG сигнала. ECoG сигнал снимался с 64х электродов, частотой 1кГц. Чтобы сформировать тензор признаков, каждая эпоха ECoG была сопоставлена с временно-частотно-пространственным пространством с помощью непрерывного волнового преобразования (CWT).

Снижение размерности. Задача состоит в поиске функций $\phi : X^{n \times m} \rightarrow X^{n \times k}$ для объектов и функции $\psi : Y^{n \times p} \rightarrow X^{n \times q}$ для кодирования целевых переменных. Причем $k < m, q < p$. Полученные матрицы являются матрицами представлений в латентном пространстве.

Рассматриваются линейные и нелинейные модели. Линейные модели менее подвержены проклятию размерности и слабее переобучаются, а нелинейные методы способны уловить сложные закономерности. Чтобы объединить преимущества обоих методов рассматриваются generalized linear models, additive models и их комбинация — GAM.

Линейная модель задается в виде $\hat{y} = X^T \theta + \theta_0$, где X — матрица признаков, а θ — вектор параметров модели. Предполагается, что истинная зависимость так же является линейной, с шумом, распределенным нормально.

GLM — обобщение линейной регрессии, в котором мы можем применять разные функции к y , а так же предполагать разные его распределения.

AM — еще один способ по внедрению нелинейности в модель. $\hat{y} = \theta_0 + \sum \theta_i f_i(x_i)$.

Используемые метрики и критерии качества: $MSE(\|y - \hat{y}\|_2^2)$, $MAE(\|y -$

$$\hat{y}||_1), MAPE(\frac{1}{n} \sum \frac{|Y_i - \hat{Y}_i|}{Y_i}).$$

Соответственно задача ставится как минимизация этих Loss-function:

$$L(X, Y, \Theta) \rightarrow \min.$$

4 Вычислительный эксперимент

4.1 Цель

Обучить базовую модель PLS на преобразованных данных и сравнить с моделью линейной регрессии. Визуализировать полученные результаты.

4.2 Описание датасета

Датасет состоит из 20-ти записей двух обезьян, которые пытались достать кусочек еды правой рукой. Преобразованные с помощью непрерывного волнового преобразования данные представляют собой тензор $X \in \mathbb{R}^{T,K,W+1}$, где W — размерность для волновых коэффициентов преобразования. Кроме того, к данным добавлен исходная матрица матрица временных рядов для каждого датчика. Y остается неизменной. Данные подготовлены Анастасией Мотренко и уже подеелны на обучающую и тестовую выборки. Обучающая выборка имеет следующую размерность: $X : (12801, 32, 27)$, где 12801 — количество временных отметок, 32 — количество электродов, 27 — количество частот для построения коэффициентов преобразования и еще одно значение, отвечающее напряжению на датчике при фиксированомом моменте времени и номере датчика. $Y : (12801, 3)$, соответственно для каждой отметки времени имеется три координаты позиции кисти.



4.3 План

Прежде чем применять алгоритмы сгенерируем дополнительно признаки — экспоненцируем существующие. Такая синтезация будет полезной, так как значения признаков слабо отличаются друг от друга и алгоритму сложнее будет искать закономерности. А при экспоненцировании разницы между значениями станут существенными. После этого обучим базовую модель PLS. Опытным путем подберем оптимальную размерность латентного пространства для этого алгоритма. Посмотрим на графики предсказаний и истинных значений по всем трем координатам. Так же построим истинную и предсказанную траекторию в трехмерном пространстве. В конце сравним с результатом работы линейной регрессии и убедимся, что применение PLS было оправданным, размерность и правда очень большая для обычной линейной регрессии.

4.4 Выполнение


После генерации фичей и применения алгоритма PLS получили на тестовых данных следующие предсказания.






Посмотрим на предсказания в 3D.

Сравнение истинной и предсказанной траектории в 3D.



И наконец, применим модель линейной регрессии.



4.5 Результаты

Из графиков можно сделать вывод, что уже сейчас, используя только баловый алгоритм PLS удалось определять основные закономерности и пики в движении. Стоит отметить, что особенно хорошо определялись именно резкие изменения по координатам, а когда кисть не двигалась, предсказания были не точными и шумными. Это не удивительно, ведь когда мозг посылает сигналы руке, он думает не о координате руки, а о силе, которую надо приложить мышце, то есть по второму закону Ньютона, об ускорении руки. Иными словами, при одинаковых сигналах мозга траектория движения руки будет одинаковой, не зависимо от того, находимся ли мы в точке $(0, 0, 0)$ или в точке $(100, 100, 100)$, так что предсказывать напрямую координату по сигналам мозга не совсем правильно. Кроме того, видно, что обычная линейная регрессия не добилась хоть каких-то результатов. Таким образом имеет смысл использовать алгоритмы понижения размерности. В будущем предполагается оценить предсказания алгоритма по функциям риска, указанных выше.

5 Литература

Список литературы

- [1] Aksenova T. Eliseyev A. Stable and artifact-resistant decoding of 3d hand trajectories from ecog signals using the generalized additive model. *Journal of neural engineering.*, 2014.
- [2] Strijov V.V. Isachenko R.V. Quadratic programming optimization with feature selection for non-linear models. *Lobachevskii Journal of Mathematics*, pages 39(9) : 1179–1187., 2018.

- [3] Strijov V.V. Motrenko A.P. Multi-way feature selection for ecog-based brain-computer interface. *Expert Systems with Applications*, 114(30), pages 402–413., 2018.
- [4] Исаченко Р.В. Выбор модели декодирования сигналов в пространствах высокой размерности. *Рукопись*, 2021.
- [5] Стрижов В.В. Яушев Ф.Ю., Исаченко Р.В. Модели согласования скрытого пространства в задаче прогнозирования. *Системы и средства информатики*, page 31(1), 2021.